

机器学习： 基于多种聚类方法的客户细分实验

2351274 王亦玮 2350233 叶辰 2350231 高柏舟

1 课题综述

1.1 课题简介

在无监督学习中，聚类是最基础也是最常用的一类方法，其目标是在没有标签的情况下自动发现数据中的“自然群体”。本实验围绕现实中的客户细分场景，选用公开的 **Segmentation Data** 数据集，在此基础上对比三种典型聚类算法：划分式的 K-Means、层次式的 Agglomerative Clustering，以及基于密度的 DBSCAN。

相比上一轮的分类、回归实验，本次实验的一个显著特点是**完全没有标签**，因此模型好坏不能简单通过准确率来衡量，而要依靠内部指标（如轮廓系数、DBI）以及对结果的可解释性和业务合理性进行综合评估。这也更贴近真实的数据分析流程：算法结果往往只是“起点”，真正有价值的是分析背后隐藏的客户结构和行为模式。

1.2 课题目标

- 通过对原始客户数据进行聚类，将用户自动划分为若干个行为特征相近的群体，用于后续市场营销策略设计；
- 对比三种聚类方法在指标（轮廓系数、DBI）、稳定性和可解释性上的差异；
- 探讨 K 值、Eps 等关键超参数的选择方法，并给出简单的优化建议；
- 在分析过程中训练自己从“算法结果”回到“业务问题”的思考习惯，而不是只盯着分数。

1.3 课题数据集

实验使用的 `segmentation-data.csv` 为结构化表格数据，共约 2000 条记录，主要字段如下：

- Sex：性别（0：男，1：女）；
- Marital status：婚姻状态（0：单身，1：非单身）；
- Age：年龄；

- Education: 教育程度 (0-3);
- Income: 年收入 (连续值, 单位约为货币的整数);
- Occupation: 职业等级 (0-2);
- Settlement size: 居住地规模 (0: 小城市, 1: 中等城市, 2: 大城市)。

为了直观展示数据的结构, 可以简单将特征按照“人口属性”和“经济属性”划分, 如表 1 所示, 这有助于后面对各簇做解释。

表 1: 特征大类划分示意

类别	含义	具体字段
人口属性	个体背景信息	Sex, Marital status, Age, Education
经济与地域属性	收入与居住环境	Income, Occupation, Settlement size

可以看出, 该数据集同时包含连续型特征 (Age、Income) 和序数型/类别特征 (Education、Occupation 等), 特征维度不高, 但量纲差异明显, 尤其是 Income 的数值远大于其他特征, 这为基于距离的聚类算法带来了直接挑战。

2 实验报告设计

2.1 数据准备

数据采用 `pandas.read_csv` 从本地读取, 并在加载后立即将纯 ID 列删除, 以避免其对距离计算产生干扰。核心思路如代码 1 所示:

Listing 1: 数据加载与基础清洗

```
1 import pandas as pd
2
3 # 读取数据
4 df = pd.read_csv("segmentation-data.csv")
5 df_original = df.copy() # 备份一份原始数据
6
7 # 删除纯 ID 列
8 for col in ["ID", "CustomerID"]:
9     if col in df.columns:
10         df = df.drop(columns=[col])
11
12 print(df.shape)
13 print(df.head())
```

随后对数据进行基本描述性统计, 确认不存在大规模缺失和异常值。实际检查发现, 该数据集质量较好, 只在个别字段存在少量空值; Age 和 Income 的分布基本符合常识, 没有明显的逻辑错误值 (如负数年龄)。

2.2 数据清洗

2.2.1 缺失值处理与特征划分

按照特征类型进行划分并分别处理：

- 数值特征 (Age, Income 等)：使用中位数填补缺失；
- 类别/序数特征 (Sex, Education 等)：使用众数填补缺失。

下面给出简化代码示意（省略异常处理等细节），突出处理流程：

Listing 2: 缺失值处理与特征划分

```
1 import numpy as np
2
3 # 按类型划分特征
4 numerical_features = df.select_dtypes(include=[np.number]).columns.
    tolist()
5 categorical_features = df.select_dtypes(exclude=[np.number]).columns.
    tolist()
6
7 # 数值特征：用中位数填补
8 for col in numerical_features:
9     df[col] = df[col].fillna(df[col].median())
10
11 # 类别/序数特征：用众数填补
12 for col in categorical_features:
13     df[col] = df[col].fillna(df[col].mode()[0])
```

这种处理方式虽然非常“朴素”，但对于本数据集这种缺失比例非常低的情况已经足够，而且不会引入复杂的假设，便于后续复现实验结果。

2.2.2 标准化与编码

由于本实验中所有聚类算法都采用欧氏距离，必须消除特征间的量纲差异。我们使用 **StandardScaler** 对数值特征进行 Z-Score 标准化，将每个特征变换为均值为 0、方差为 1 的分布：

$$x^{(new)} = \frac{x - \mu}{\sigma}$$

对于本数据集，非数值特征已经是 0/1 或有限整数编码，为简化起见我们没有再做 One-Hot 展开，而是统一参与标准化处理，使其在距离空间中与连续特征处于同一数量级。预处理核心代码思路如下：

Listing 3: 数值标准化

```
1 from sklearn.preprocessing import StandardScaler
2
3 scaler = StandardScaler()
4 X_processed = scaler.fit_transform(df[numerical_features])
5 # 若需要也可将类别特征拼接，这里略
```

实际测试表明，这种处理在三种聚类算法上的表现都比较稳定，没有出现某个特征“支配”距离计算的情况。预处理后的结果为一个纯数值矩阵 $X_{\text{processed}}$ ，将作为后续各聚类算法的输入。

2.3 模型搭建

本实验实现了三类聚类方法，整体策略是：**先用指标和可视化选参数，再固定参数进行对比。**

2.3.1 K-Means 聚类

K-Means 的目标是最小化簇内平方误差：

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

算法迭代执行“分配样本到最近中心”和“按簇内均值更新中心”两步，直到中心基本不再移动。

K 值选择 (肘部法则) 我们在 $K = 2 \sim 10$ 上遍历，记录每个 K 对应的 SSE (Inertia)，绘制如图 1 所示的肘部曲线：




图 1: 肘部法则: K 对 SSE 的影响

曲线在 $K = 4 \sim 6$ 之间开始明显变缓，存在“肘部”；同时考虑到希望细分出较丰富的客户群，本实验最终 **手动选择** $K = 6$ 作为 K-Means 的聚类数。

K-Means 模型要点 实现上使用 sklearn 的 KMeans，只保留关键配置：

Listing 4: K-Means 模型主要参数

```
1 from sklearn.cluster import KMeans
```

```
2
3 kmeans = KMeans(
4     n_clusters = 6,
5     random_state = 42,
6     n_init = 10,
7     max_iter = 300
8 )
9
10 labels_kmeans = kmeans.fit_predict(X_processed)
```

其中 `n_init` 设置为 10，是为了降低随机初始化导致的局部最优风险。

2.3.2 DBSCAN 聚类

DBSCAN 通过密度连通性自动发现簇，并能自然标记噪声点。关键参数为：邻域半径 ϵ 和邻域内最少点数 `MinPts`。

Eps 选择 (K-距离图) 我们取 `MinPts = 5`，计算每个样本到其第 5 个最近邻的距离，排序后绘制 K-距离图，如图 2 所示：




图 2: DBSCAN K-距离图用于选择 ϵ

曲线在约 1.6 左右出现明显拐点，表示从稠密区域过渡到稀疏区域。综合多次试验，本实验取 $\epsilon = 1.65$ 、`MinPts = 5`。

模型使用：

Listing 5: DBSCAN 模型构建

```
1 from sklearn.cluster import DBSCAN
2
3 dbscan = DBSCAN(eps=1.65, min_samples=5)
4 labels_dbscan = dbscan.fit_predict(X_processed)
```

聚类后将噪声点标签记为 -1，其余点按 0,1,2,... 编号。

2.3.3 层次聚类 (Agglomerative)

层次聚类采用自底向上策略：初始每个样本自成一簇，每次合并距离最近的两个簇。我们选择 **Ward** 链接（最小化簇内方差增加），并通过树状图来确定合适的簇数。

K 值选择 (树状图) 基于预处理后的数据计算 Ward 链接矩阵，并绘制 Dendrogram，如图 3 所示：




图 3: 层次聚类树状图 (Ward 链接)

在高度约为 10 的位置画水平线可以得到 6 个主要分支，与 K-Means 的 $K=6$ 一致，因此层次聚类也设置 $K=6$ 。

模型使用：

Listing 6: Agglomerative 模型构建

```
1 from sklearn.cluster import AgglomerativeClustering
2
3 agгло = AgglomerativeClustering(
4     n_clusters = 6,
5     linkage = 'ward'
6 )
7
8 labels_agglo = agгло.fit_predict(X_processed)
```

2.4 模型训练测试

三种聚类方法均在标准化后的特征矩阵 $X_{\text{processed}}$ 上进行训练。对于 K-Means 与 Agglomerative 聚类，所有样本都会被分配到某一个簇中；对于 DBSCAN，部分样本会被标记为噪声点（标签 -1）。

后续的内部评估指标（轮廓系数、DBI）以及特征均值画像、业务解释等，均基于这些训练得到的簇标签进行计算和分析。

2.5 结果可视化

2.5.1 PCA 降维方法与解释方差

为了在二维平面上展示高维聚类结果，我们使用 PCA（主成分分析）将标准化后的特征降到 2 维。PCA 的核心思想是找到数据方差最大的方向，使得用少数几个主成分就能保留原始数据的大部分信息。

本数据集的 7 维特征在降维到 2 维后，前两个主成分的解释方差比例约占总方差的 60% 左右。这意味着虽然有 40% 的信息在投影过程中被压缩，但主要的数据结构特征仍被保留，足以用于聚类结果的可视化和直观理解。

特别要注意的是，降维仅用作可视化工具，原始的聚类计算是在高维空间（7 维）中进行的，不受 PCA 投影的影响。这样做可以避免“聚类 → 降维”顺序导致的信息偏差。

2.5.2 K-Means 聚类结果与分析

基于 PCA 的二维散点图如图 4 所示，颜色表示不同簇，红色叉号为簇中心（即质心）：




图 4: K-Means 聚类结果 (K=6, PCA 降维)

从图中可以看到以下特点：

- 空间分布：六个簇在 PCA 平面上大体呈条带状分布，彼此有较清晰的分离界面，说明 K-Means 算法成功捕捉到了数据的主要聚集趋势；

- 内部紧凑性：各簇内部的点比较集中，质心（红色叉号）位于密度中心附近，表明中心选择相对合理；
- 边界模糊性：中间区域存在部分交叠，说明不同客户群之间存在连续过渡，这是很多真实数据集的特点，说明我们的 $K=6$ 选择是合理的（既不过细分，也不过粗糙）。

2.5.3 层次聚类结果与对比

层次聚类在相同的 PCA 空间中的结果如图 5：




图 5: Agglomerative 聚类结果 ($K=6$, PCA 降维)

总体形态与 K-Means 高度相似，说明在 Ward 链接下层次聚类与 K-Means 学到的是同一套簇结构。这种一致性带来的好处是：

- 结果稳定性强：两种不同逻辑的算法得到相同结论，大大增强了结果的可信度；
- 降低误差风险：若只用 K-Means，可能存在初始化不良导致的局部最优；若两者都同意这个聚类结果，则误导的可能性很小；
- 业务解释简洁：可以用单一的簇结构来解释所有客户群体。

2.5.4 DBSCAN 聚类结果与特异性分析

DBSCAN 的二维结果见图 6，标签 -1 的点为噪声点：




图 6: DBSCAN 聚类结果 (Eps=1.65, MinPts=5)

可以观察到：

- 密度优先：DBSCAN 主要识别出若干密集簇（约 4-5 个），同时将边缘、孤立的点标记为噪声（黑色或灰色点）；
- 形状灵活性：与 K-Means 假设的“球形簇”不同，DBSCAN 的簇形状不再局限于“圆团”，而是沿着数据的真实分布伸展，更贴近现实数据的几何特性；
- 噪声比例适中：噪声点数量约占总体的 5%-10%，既不至于太多（导致结果不稳定），也不至于太少（无法识别真正的异常值），为后续异常客户分析提供了基础。

三种方法的对比表明：K-Means 和层次聚类追求全覆盖和全局最优，而 DBSCAN 追求密度连通性和局部最优。两种思路各有优劣，企业可根据具体需求选择。

2.6 分析和优化

2.6.1 聚类特征分析（多模型结果对比）

为了赋予每个簇具体的业务含义，我们在原始空间中计算各簇的特征均值，并绘制特征画像。

K-Means 各簇画像与业务解释 图 7 展示了 K-Means 六个簇在 Sex、Age、Education、Income 等特征上的平均值：




图 7: K-Means 各簇特征均值画像

结合均值数据，可得到大致画像示例（仅列出几类）：

- **簇 A（年轻低收入群）**：年龄较小（如平均 25–30 岁）、教育程度偏低、收入水平明显低于总体，主要分布在小城市。这一群体可能主要由学生或初入职场的年轻人构成，消费潜力尚未完全释放，但对价格较为敏感。营销策略可聚焦于“价格优惠”和“分期付款”等吸引力点。
- **簇 B（高学历高收入群）**：年龄在中年段（如平均 40–50 岁），受教育程度较高（Education=2.5+），收入显著高于平均水平（Income > 5000 等），多集中在大城市。这一群体是典型的高价值客户，具有较强的消费能力，对服务品质的要求可能高于价格，倾向于选择高端品牌和增值服务。营销策略应侧重于“品质承诺”和“VIP 待遇”。
- **簇 C（中产稳定群）**：年龄、收入均接近全体平均，婚姻和职业状态较为稳定，可视为“主流大众客户”。这一群体的基数最大，消费行为相对稳健，是企业维持基

本盘的关键。营销策略应面向“家庭需求”和“生活品质提升”。

不同簇在 Education、Income、Settlement size 上的显著差异，为后续制定分级营销策略提供了强有力的量化依据。例如，对年轻群体可推送高性价比的基础套餐，而对高收入群体则应侧重推荐高端增值服务。

层次聚类各簇画像与稳定性验证 图 8 为层次聚类的特征均值图：




图 8: Agglomerative 各簇特征均值画像

可以发现各簇在 Age、Income、Education 等维度上的趋势几乎与 K-Means 完全一致。具体来说：

- 最低收入簇和最高收入簇的位置完全相同；
- Age 分布的梯度也是一样的；

- 甚至各簇的人数比例（簇大小）也基本相同。

这种高度一致性说明 Ward 链接得到的簇结构与 K-Means 的结果不是偶然的巧合，而是反映了数据的真实内在结构。因此，这个聚类结果的可信度和可解释性得到了显著增强。

DBSCAN 各簇画像与噪声分析 图 9 为 DBSCAN 的特征画像，其中噪声点（簇 -1）也计算了均值：




图 9: DBSCAN 各簇特征均值画像（含噪声簇 -1）

DBSCAN 的结果特点在于：有些簇对应于非常稠密的高收入人群或特定年龄段人群，这些是数据中的“核心模式”。而噪声簇（-1）的均值往往表现为“极端值”组合，如年龄很大或很小、收入极高或极低等，反映了那些难以被主流簇解释的个案。

在实际业务场景中，这些噪声点极具分析价值：

- 它们可能是潜在的 **VIP 客户**（超高收入但行为模式独特，可能需要特殊的高端定制方案）；
- 也可能是 **高风险客户**（如信用欺诈、异常交易等，需要额外的风控措施）；
- 或者仅仅是 **脏数据**（数据采集或录入错误）。

通过 DBSCAN 将这些点从主流群体中剥离出来，可以帮助运营人员进行更精细化的个案排查，从而实现“1 对 1”的精准运营。

2.6.2 内部评估指标与含义

我们采用两种常见的内部指标来量化聚类质量：

轮廓系数 (Silhouette Coefficient) 对每个样本计算 a_i （该样本到同簇其他点的平均距离）和 b_i （该样本到最近异簇中所有点的平均距离），然后：

$$\text{Silhouette}_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

轮廓系数范围在 $[-1, 1]$ ，值越大说明该样本聚类越好。整体轮廓系数是所有样本的平均值，越接近 1 表示簇的紧凑性和分离性都很好。

Davies-Bouldin Index (DBI) DBI 衡量簇内的平均相似度与簇间的平均距离的比值，越小越好。DBI 越小说明簇之间距离越远、簇内越紧凑。

典型结果（取一次运行的代表值）如下：

表 2: 三种聚类方法的内部指标（示意）

方法	关键参数	轮廓系数	DBI
K-Means	K=6	约 0.26	约 1.35
Agglomerative	K=6, Ward 链接	约 0.26	约 1.38
DBSCAN (非噪声)	Eps=1.65, MinPts=5	约 0.31	约 1.10

可以看到，在剔除噪声点后，DBSCAN 的轮廓系数和 DBI 略优于另外两种方法。这与它专注于密集核心簇、自动丢弃边缘点的机制是一致的：剩下的“好簇”当然指标更漂亮。然而，这个对比需要在理解“覆盖率”的前提下进行——DBSCAN 的“覆盖率”往往低于前两者（因为它丢弃了部分难分类的样本），而 K-Means 则是强制将所有样本归类到某一簇，即使分配不理想也要包括。

从不同角度：

- 若追求 **全样本聚类**（不允许离群点），K-Means 和层次聚类更合适；
- 若追求 **高质量聚类和异常检测并重**，DBSCAN 更合适。

2.6.3 方法优缺点深度小结

K-Means

- 优点：实现简单、计算速度快（时间复杂度 $O(nkd)$ ）、对大数据友好、结果易解释（质心就是簇的代表）、适合实时应用；
- 缺点：需预设 K ，对异常值敏感（一个极端值可能拉动整个簇的中心），假设簇近似球形（对细长簇效果差），容易陷入局部最优。
- 适用场景：追求全覆盖、高效率的一般性分群任务，如营销分级、客户分层等。

层次聚类（Ward）

- 优点：不必预先指定 K ，可通过树状图直观观察簇的形成过程，选择分割高度很灵活，结果可解释性好；
- 缺点：时间复杂度高（ $O(n^2)$ ），不适合更大规模数据（几万条以上开始变慢），一旦合并无法回退（贪心策略的局限），距离矩阵可能很大；
- 适用场景：数据量中等、需要探索层级结构或进行多个粒度的聚类的任务。

DBSCAN

- 优点：不需预设簇数（自动确定），可发现任意形状簇（不局限于凸集），自动标记噪声点（便于异常检测），对异常值鲁棒；
- 缺点： Eps 对结果非常敏感（稍微改变 Eps 可能导致完全不同的聚类结果），高维数据中“距离”的定义不再可靠（维度灾难），参数调优难度高；
- 适用场景：对异常检测有需求、簇形状非常不规则、或数据中本身存在噪声点需要剥离的场景。

2.6.4 优化思路与业务建议

参数与流程层面的优化

- 对 K-Means：可在肘部附近多试几个 K 值（如 $K=5, 7, 8$ ），并结合业务需求（运营上需要多少档客户等级）综合确定。也可尝试轮廓系数（Silhouette Score）来辅助选择 K ；
- 对 DBSCAN：可在 K -距离图拐点附近对 Eps 做细粒度搜索（如 1.5、1.6、1.7 等），同时观察噪声比例与簇结构的变化，寻找“最稳定”的那个 Eps 值；
- 维度优化：可以尝试先用 PCA 或其他降维方法降到 3-4 维，再进行各种聚类，以减轻维度灾难影响（特别是对 DBSCAN）。或者使用针对高维数据的距离度量（如余弦相似度）替代欧氏距离。

面向客户细分的业务建议

- 将 K-Means/层次聚类得到的主流簇作为标准客群分层：如“年轻低收入群”“高学历高收入群”“大众中产群”等，对应设计差异化营销方案（pricing、产品推荐、沟通渠道等均可根据簇的特性定制）；
- 将 DBSCAN 的噪声点作为特殊人群，针对性排查是否存在潜在高价值客户（超高收入但被标记为噪声）或高风险客户（异常行为），实现“特殊待遇”或“重点监控”；
- 后续可在每个簇内部再叠加监督学习模型（如在簇内做信用评分、购买预测或留存率预测），实现“先聚类再建模”的两阶段策略，大大提升模型的可解释性和泛化能力。

3 总结

本实验围绕 Segmentation Data，完整实现了 K-Means、Agglomerative、DBSCAN 三种聚类方法，对比了它们在参数选择、簇形状适应性、异常值处理能力和内部指标上的表现。通过 PCA 可视化和特征均值画像，给出了较为直观的客户群体解释。总体来看：

1. K-Means 与 Ward 层次聚类在本数据集上得到高度一致的簇结构，适合用作主流客户分层工具。它们都强调“全覆盖”和“全局最优”，适合对所有顾客都要给出明确分类的业务场景；
2. DBSCAN 更适合定位密集核心簇和异常客户，可作为补充视角。它的“宽容”让一些边缘案例浮出水面，便于企业进行 1 对 1 的精准运营；
3. 标准化、参数调优和结果解释是聚类实验中最关键的三个环节。任何一环的缺失都可能导致错误的业务结论。特别是“结果解释”往往被忽视，而它是连接数据世界和业务世界的关键桥梁。

在后续工作中，可以尝试引入高斯混合模型（提供概率上的簇分配而非硬分配）、谱聚类（对复杂数据分布更鲁棒）等更复杂的方法，与本实验结果进行进一步对比；也可以引入真实业务指标（如转化率、贡献利润、客户生命周期价值等），从业务效果角度反向验证聚类质量，从而实现从“数据聚类”到“商业价值”的闭环。这样才能让数据科学真正服务于业务决策。

组员及任务分配情况

- **王亦玮** (2351274)：负责数据准备与预处理、DBSCAN 模型搭建及主要代码实现。
- **叶辰** (2350233)：负责层次聚类模型搭建及主要代码实现、优化建议及实验报告整理撰写。
- **高柏舟** (2350231)：负责 K-means 模型搭建及主要代码实现、评估指标计算、结果对比分析。