

第三章 鸽巢原理

刘关俊

liuguanjun@tongji.edu.cn

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.1 (丢番图逼近) 对任意实数 x 和正整数 n , 总存在整数 p 和 q 满足

$$\left| x - \frac{p}{q} \right| < \frac{1}{qn}, \quad (3.1)$$

其中: $1 \leq q \leq n$ 。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.1 (丢番图逼近) 对任意实数 x 和正整数 n , 总存在整数 p 和 q 满足

$$\left| x - \frac{p}{q} \right| < \frac{1}{qn}, \quad (3.1)$$

其中: $1 \leq q \leq n$ 。

证明: 给定一个实数 x , 记 $\{x\}$ 为 x 的小数部分。区间 $[0, 1)$ 划分为 n 个等长的子区间:

$$\left[0, \frac{1}{n}\right), \left[\frac{1}{n}, \frac{2}{n}\right), \dots, \left[\frac{n-1}{n}, 1\right)。$$

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.1 (丢番图逼近) 对任意实数 x 和正整数 n , 总存在整数 p 和 q 满足

$$\left| x - \frac{p}{q} \right| < \frac{1}{qn}, \quad (3.1)$$

其中: $1 \leq q \leq n$ 。

证明: 给定一个实数 x , 记 $\{x\}$ 为 x 的小数部分。区间 $[0, 1)$ 划分为 n 个等长的子区间:

$$\left[0, \frac{1}{n}\right), \left[\frac{1}{n}, \frac{2}{n}\right), \dots, \left[\frac{n-1}{n}, 1\right)。$$

$0x, 1x, \dots, nx$ 这 $n + 1$ 个实数的小数部分中必有两个落在同一个子区间内

不妨设 $\{k_1x\}$ 与 $\{k_2x\}$ 落在同一子区间内且 $0 \leq k_1 < k_2 \leq n$, 则下式成立:

$$|\{k_2x\} - \{k_1x\}| < \frac{1}{n}。$$

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.1 (丢番图逼近) 对任意实数 x 和正整数 n , 总存在整数 p 和 q 满足

$$\left| x - \frac{p}{q} \right| < \frac{1}{qn}, \quad (3.1)$$

其中: $1 \leq q \leq n$ 。

证明: 给定一个实数 x , 记 $\{x\}$ 为 x 的小数部分。区间 $[0, 1)$ 划分为 n 个等长的子区间:

$$\left[0, \frac{1}{n}\right), \left[\frac{1}{n}, \frac{2}{n}\right), \dots, \left[\frac{n-1}{n}, 1\right).$$

$0x, 1x, \dots, nx$ 这 $n + 1$ 个实数的小数部分中必有两个落在同一个子区间内不妨设 $\{k_1x\}$ 与 $\{k_2x\}$ 落在同一子区间内且 $0 \leq k_1 < k_2 \leq n$, 则下式成立:

$|\{k_2x\} - \{k_1x\}| < \frac{1}{n}$ 。令 $a = k_1x - \{k_1x\}$ 、 $b = k_2x - \{k_2x\}$, 则

$$|(k_2 - k_1)x - (b - a)| = |(k_2x - b) - (k_1x - a)| = |\{k_2x\} - \{k_1x\}| < \frac{1}{n}。$$

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.2 在 $n + 1$ 个互不相等且均小于或等于 $2n$ 的正整数中, 必然存在两个互素的数。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.2 在 $n + 1$ 个互不相等且均小于或等于 $2n$ 的正整数中, 必然存在两个互素的数。

证明: 若 $n + 1$ 个互不相等的正整数均小于或等于 $2n$, 则它们中的某两个必相邻、从而互素。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.2 在 $n + 1$ 个互不相等且均小于或等于 $2n$ 的正整数中, 必然存在两个互素的数。

证明: 若 $n + 1$ 个互不相等的正整数均小于或等于 $2n$, 则它们中的某两个必相邻、从而互素。

将 1 和 2 放在一个盒子中、3 和 4 放在一个盒子中、 $\dots$ 、 $2n - 1$ 和 $2n$ 放在一个盒子中, 若想从这 n 个盒子的 $2n$ 个数中取出 $n + 1$ 个不同的数, 必然某个盒子中的两个数都被取出。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.3 (斐波那契数的余数周期性) 已知正整数 $m > 1$, 则 $\langle F(n) \bmod m \rangle_{n \geq 0}$ 是一个周期性的数列。

$\langle 0, 1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, \dots \rangle$ 。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.3 (斐波那契数的余数周期性) 已知正整数 $m > 1$, 则 $\langle F(n) \bmod m \rangle_{n \geq 0}$ 是一个周期性的数列。

$\langle 0, 1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, \dots \rangle$ 。

n	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$F(n)$	0	1	1	2	3	5	8	13	21	34	55	89	144	233	377	610
$F(n) \bmod 2$	0	1	1	0	1	1	0	1	1	0	1	1	0	1	1	0
$F(n) \bmod 3$	0	1	1	2	0	2	2	1	0	1	1	2	0	2	2	1
$F(n) \bmod 4$	0	1	1	2	3	1	0	1	1	2	3	1	0	1	1	2

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.3 (斐波那契数的余数周期性) 已知正整数 $m > 1$, 则 $\langle F(n) \bmod m \rangle_{n \geq 0}$ 是一个周期性的数列。

证明: 斐波那契数列中的数除以 m 所能得到的余数最多有 m 个; 因此, 余数数列 $\langle F(n) \bmod m \rangle_{n \geq 0}$ 中相邻的余数对最多有 m^2 种情况; 由于该余数数列中有无穷多个相邻的余数对, 所以依据鸽巢原理可知: 必然存在两对余数, 不妨设其为 $(F(k) \bmod m, F(k+1) \bmod m)$ 与 $(F(j) \bmod m, F(j+1) \bmod m)$, 满足

$$\underline{k < j \wedge (F(k) \bmod m, F(k+1) \bmod m) = (F(j) \bmod m, F(j+1) \bmod m)}.$$

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.3 (斐波那契数列) 斐波那契数列 $\langle F(n) \mod m \rangle_{n \geq 0}$ 是一个周期性的数列。

证明: 斐波那契数列 $\langle F(n) \mod m \rangle_{n \geq 0}$ 有 m 个; 因此, 余数由于该余数数列中有无穷多个相邻的余数对 $(F(k) \mod m, F(k+1) \mod m)$ 与 $(F(j) \mod m, F(j+1) \mod m)$ 相同, 不妨设其为 $(F(k) \mod m, F(k+1) \mod m) = (F(j) \mod m, F(j+1) \mod m)$, 满足

$$\begin{cases} F(k-1) \mod m = F(j-1) \mod m \\ F(k-2) \mod m = F(j-2) \mod m \\ \vdots \\ F(1) \mod m = F(j-(k-1)) \mod m \\ F(0) \mod m = F(j-k) \mod m \end{cases}$$

$k < j \wedge (F(k) \mod m, F(k+1) \mod m) = (F(j) \mod m, F(j+1) \mod m)$ 。

3.1 鸽巢原理的简单形式

鸽巢原理 (pigeonhole principle), 又称抽屉原理 (drawer principle) 或狄利克雷原理 (Dirichlet principle), 其简单形式表述如下:

定理 3.1 (鸽巢原理简单形式) 若把 $n + 1$ 个物品放入 n ($n > 0$) 个盒子中, 则至少有一个盒子放入了至少两个物品。

例 3.3 (斐波那契数列) 斐波那契数列 $\langle F(n) \mod m \rangle_{n \geq 0}$ 是一个周期性的数列。证明: 斐波那契数列 $\langle F(n) \mod m \rangle_{n \geq 0}$ 有无穷多个相邻的余数对 $(F(k) \mod m, F(k+1) \mod m)$ 满足

$$\begin{cases} F(k-1) \mod m = F(j-1) \mod m \\ F(k-2) \mod m = F(j-2) \mod m \\ \vdots \\ F(1) \mod m = F(j-(k-1)) \mod m \\ F(0) \mod m = F(j-k) \mod m \end{cases}$$

则 $\langle F(n) \mod m \rangle_{n \geq 0}$ 有 m 个; 因此, 余数对 $(F(k) \mod m, F(k+1) \mod m)$ 有 m^2 对; 由于该余数数列中有无穷多个相邻的余数对, 不妨设其为 $(F(k) \mod m, F(k+1) \mod m)$ 和 $(F(j) \mod m, F(j+1) \mod m)$, 满足

$$\underline{k < j \wedge (F(k) \mod m, F(k+1) \mod m) = (F(j) \mod m, F(j+1) \mod m)}.$$

$\langle F(0) \mod m, F(1) \mod m, \dots, F(j-k-1) \mod m \rangle$ 是周期性出现

3.2 鸽巢原理的一般形式

定理 3.2 (鸽巢原理一般形式) 令 $a_1, a_2, \dots, a_n, n$ 是正整数。若把多于 $a_1 + a_2 + \dots + a_n$ 个的物品放入 n 个盒子中, 则存在一个 $k \in \{1, 2, \dots, n\}$ 使得第 k 个盒子至少有 $a_k + 1$ 个物品。

推论 3.1 令 m 与 n 是两个正整数。若把多于 mn 个的物品放入 n 个盒子中, 则至少有一个盒子放入了至少 $m + 1$ 个物品。

推论 3.2 令 $a_1, a_2, \dots, a_n, n$ 是正整数。若把 $a_1 + a_2 + \dots + a_n - n + 1$ 个的物品放入 n 个盒子中, 则存在一个 $k \in \{1, 2, \dots, n\}$ 使得第 k 个盒子至少放入了 a_k 个物品。

推论 3.3 令 m 与 n 是两个正整数。将 m 个的物品放入 n 个盒子中, 则至少有一个盒子放入了至少 $\lceil m/n \rceil$ 个物品, 这里 $\lceil m/n \rceil$ 表示对 m/n 的值上取整。

定理 3.3 令 m 与 n 是两个正整数。将不多于 m 个的物品放入 n 个盒子中, 则至少有一个盒子放入了至多 $\lfloor m/n \rfloor$ 个物品。

3.2 鸽巢原理的一般形式

例 3.4 (单调子数列问题) 已知两个正整数 m 和 n ，则一个长度大于 mn 的实数数列中，或者有一个长度是 $m+1$ 的递增子数列，或者有一个长度是 $n+1$ 的严格递减子数列。

证明：考虑长度为 $mn+1$ 的实数数列 $\langle a_1, a_2, \dots, a_{mn+1} \rangle$ ，假设其任何递增子数列的长度都不超过 m ，下证其必包含一个长度为 $n+1$ 的严格递减子数列。

3.2 鸽巢原理的一般形式

例 3.4 (单调子数列问题) 已知两个正整数 m 和 n ，则一个长度大于 mn 的实数数列中，或者有一个长度是 $m+1$ 的递增子数列，或者有一个长度是 $n+1$ 的严格递减子数列。

证明：考虑长度为 $mn+1$ 的实数数列 $\langle a_1, a_2, \dots, a_{mn+1} \rangle$ ，假设其任何递增子数列的长度都不超过 m ，下证其必包含一个长度为 $n+1$ 的严格递减子数列。

令 l_k 是上述数列中从 a_k 开始的最长递增子数列的长度， $1 \leq k \leq mn+1$ ，则依据假设知： $1 \leq l_k \leq m$ 。依据鸽巢原理可知：在 $\{l_1, l_2, \dots, l_{mn+1}\}$ 中至少有 $\lceil (mn+1)/m \rceil = n+1$ 个数相等，不妨设它们为

$$l_{k_1} = l_{k_2} = \dots = l_{k_{n+1}} = k \wedge 1 \leq k_1 < k_2 < \dots < k_{n+1} \leq mn+1。$$

3.2 鸽巢原理的一般形式

例 3.4 (单调子数列问题) 已知两个正整数 m 和 n , 则一个长度大于 mn 的实数数列中, 或者有一个长度是 $m+1$ 的递增子数列, 或者有一个长度是 $n+1$ 的严格递减子数列。

证明: 考虑长度为 $mn+1$ 的实数数列 $\langle a_1, a_2, \dots, a_{mn+1} \rangle$, 假设其任何递增子数列的长度都不超过 m , 下证其必包含一个长度为 $n+1$ 的严格递减子数列。

令 l_k 是上述数列中从 a_k 开始的最长递增子数列的长度, $1 \leq k \leq mn+1$, 则依据假设知: $1 \leq l_k \leq m$ 。依据鸽巢原理可知: 在 $\{l_1, l_2, \dots, l_{mn+1}\}$ 中至少有 $\lceil (mn+1)/m \rceil = n+1$ 个数相等, 不妨设它们为

$$l_{k_1} = l_{k_2} = \dots = l_{k_{n+1}} = k \wedge 1 \leq k_1 < k_2 < \dots < k_{n+1} \leq mn+1。$$

考察这 $n+1$ 个长度相等的子数列的第一个数字 $a_{k_1}, a_{k_2}, \dots, a_{k_{n+1}}$, 可知:

$$a_{k_1} > a_{k_2} > \dots > a_{k_{n+1}},$$

即, 形成一个长度为 $n+1$ 的严格递减子数列; 此关系之所以成立, 是因为: 如果前面的一个小于或等于后面的, 譬如 $a_{k_1} \leq a_{k_2}$, 则从 a_{k_2} 开始的这个最长子数列的前面再放上 a_{k_1} 就形成一个从 a_{k_1} 开始的长度为 $k+1$ 的子数列, 与从 a_{k_1} 开始的最长子数列的长度为 k 的事实相矛盾。

3.3 应用：多索引哈希

记 $\mathbb{H} = \{h_k = (b_{k,1}b_{k,2} \cdots b_{k,d})_2 \mid k = 1, 2, \dots, n\} \subset \mathbb{B}^d$ 是一包含 n 个元素的 d 维二进制汉明空间 (binary Hamming space), 即空间中的每一个元素都是由 d 个比特构成的二进制码, 此处 $\mathbb{B} = \{0, 1\}$ 。汉明空间中任意两个二进制码 h_1 和 h_2 的汉明距离 (Hamming distance) ^⑧ 计算如下:

$$\|h_1 - h_2\|_{\mathbb{H}} = \|h_2 - h_1\|_{\mathbb{H}} = \sum_{k=1}^d [b_{1,k} \neq b_{2,k}], \quad (3.2)$$

其中: $\|\cdot\|_{\mathbb{H}}$ 又称汉明范数, 表达式 $[b_{1,k} \neq b_{2,k}]$ 为艾佛森约定。汉明距离计算两个等长二进制码之间相异比特的位置数, 用于表达两个二进制码的相似性, 如 $\|(110111)_2 - (010011)_2\|_{\mathbb{H}} = 2$; 显然, 两个二进制码的汉明距离越小, 它们越相似, 当距离为 0 时则两个二进制码完全一样。

M. Norouzi, A. Punjani and D. J. Fleet, Fast exact search in Hamming space with multi-index hashing, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 36, no. 6, pp. 1107{1119, 2014.

3.3 应用：多索引哈希

$O(n)$

唯一标识符	特征向量
id_1	1000 1110 1001 0101
id_2	0010 0111 0100 0111
id_3	1000 1111 1100 0110
id_4	0000 1111 0111 1011
id_5	0101 0111 0011 1000
id_6	1010 1100 1110 0100
id_7	1011 1110 1011 0110
id_8	1110 0101 0110 0111
id_9	0111 1001 1110 1100
id_{10}	0110 1111 0001 0011
id_{11}	1101 0110 1111 1010
id_{12}	1010 1100 0110 1011
id_{13}	0011 1011 1110 0100
id_{14}	1110 1000 0000 0101
id_{15}	1111 1010 1000 1111
id_{16}	1110 1011 1100 1110
id_{17}	0000 0001 1100 1001

3.3 应用：多索引哈希

征向量 h 划分为 m 个不相交的子向量，即

$$h = h^{(1)} h^{(2)} \dots h^{(m)},$$

且每个子向量的长度要么为 $\lceil d/m \rceil$ 要么为 $\lfloor d/m \rfloor$ ，譬如令前 $d \bmod m$ 个子向量的长度均为 $\lceil d/m \rceil$ 而剩余的子向量的长度均为 $\lfloor d/m \rfloor$ ；为便于叙述，不妨设 m 恰好整除 d 。构造 m 个哈希表，则每个表有 $2^{d/m}$ 个键用于表示如下所有可能的键值：

$$\underbrace{00 \dots 00}_{d/m}, \underbrace{00 \dots 01}_{d/m}, \dots, \underbrace{11 \dots 11}_{d/m}。$$

针对特征向量 h 的第 k 个子向量 $h^{(k)}$ ，将 h 的标识符插入到第 k 个哈希表的键值为 $h^{(k)}$ 的桶中。

3.3 应用：多索引哈希

唯一标识符	特征向量
id_1	1000 1110 1001 0101
id_2	0010 0111 0100 0111
id_3	1000 1111 1100 0110
id_4	0000 1111 0111 1011
id_5	0101 0111 0011 1000
<u>id_6</u>	<u>1010 1100 1110 0100</u>
id_7	1011 1110 1011 0110
id_8	1110 0101 0110 0111
id_9	0111 1001 1110 1100
id_{10}	0110 1111 0001 0011
id_{11}	1101 0110 1111 1010
id_{12}	1010 1100 0110 1011
id_{13}	0011 1011 1110 0100
id_{14}	1110 1000 0000 0101
id_{15}	1111 1010 1000 1111
id_{16}	1110 1011 1100 1110
id_{17}	0000 0001 1100 1001

(a)

哈希表 1	
键	桶
0000	id_4, id_{17}
0001	
0010	id_2
0011	id_{13}
0100	
0101	id_5
0110	id_{10}
0111	id_9
<u>1000</u>	id_1, id_3
1001	
1010	id_6, id_{12}
1011	id_7
1100	
1101	id_{11}
1110	id_8, id_{14}, id_{16}
1111	id_{15}

(b)

哈希表 2	
键	桶
0000	
0001	id_{17}
0010	
0011	
0100	
0101	id_8
0110	id_{11}
0111	id_2, id_5
1000	id_{14}
1001	id_9
1010	id_{15}
1011	id_{13}, id_{16}
<u>1100</u>	id_6, id_{12}
1101	
1110	id_1, id_7
1111	id_3, id_4, id_{10}

(c)

哈希表 3	
键	桶
0000	id_{14}
0001	id_{10}
0010	
0011	id_5
0100	id_2
0101	
0110	id_8, id_{12}
0111	id_4
1000	id_{15}
1001	id_1
1010	
1011	id_7
1100	id_3, id_{16}, id_{17}
1101	
<u>1110</u>	id_6, id_9, id_{13}
1111	id_{11}

(d)

哈希表 4	
键	桶
0000	
0001	
0010	
0011	id_{10}
<u>0100</u>	id_6, id_{13}
0101	id_1, id_{14}
0110	id_3, id_7
0111	id_2, id_8
1000	id_5
1001	id_{17}
1010	id_{11}
1011	id_4, id_{12}
1100	id_9
1101	
1110	id_{16}
1111	id_{15}

(e)

希望从中找到与 0011 1001 0110 0100 的汉明距离不超过 2 的特征向量
如何快速找到？

3.3 应用：多索引哈希

给定一个待检索的特征向量 g ，要通过这 m 个哈希表找到与 g 的汉明距离不超过 r ($0 \leq r \leq d$) 的那些特征向量，就是依次根据 g 的第 k 个子向量 $g^{(k)}$ ，从第 k 个哈希表中筛出汉明距离可能不超过 r 的那些特征向量，然后再逐条计算这些特征向量与 g 的汉明距离，得到汉明距离真正不超过 r 的那些特征向量。上述过程通常称为 r -近邻搜索 (r -neighbor search)， r 称为检索半径 (search radius)。

而那些被筛掉的，其汉明距离均大于 r

3.3 应用：多索引哈希

给定一个待检索的特征向量 g ，要通过这 m 个哈希表找到与 g 的汉明距离不超过 r ($0 \leq r \leq d$) 的那些特征向量，就是依次根据 g 的第 k 个子向量 $g^{(k)}$ ，从第 k 个哈希表中筛出汉明距离可能不超过 r 的那些特征向量，然后再逐条计算这些特征向量与 g 的汉明距离，得到汉明距离真正不超过 r 的那些特征向量。上述过程通常称为 r -近邻搜索 (r -neighbor search)， r 称为检索半径 (search radius)。

而那些被筛掉的，其汉明距离均大于 r

定理 3.4 如果 $\|h - g\|_{\mathbb{H}} \leq r$ ，则存在正整数 $k \in [1, m]$ 满足

$$\|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \leq \lfloor r/m \rfloor. \quad (3.3)$$

证明：依据鸽巢原理 (定理 3.3) 可得该结论：

定理 3.3 令 m 与 n 是两个正整数。将不多于 m 个的物品放入 n 个盒子中，则至少有一个盒子放入了至多 $\lfloor m/n \rfloor$ 个物品。

3.3 应用：多索引哈希

给定一个待检索的特征向量 g ，要通过这 m 个哈希表找到与 g 的汉明距离不超过 r ($0 \leq r \leq d$) 的那些特征向量，就是依次根据 g 的第 k 个子向量 $g^{(k)}$ ，从第 k 个哈希表中筛出汉明距离可能不超过 r 的那些特征向量，然后再逐条计算这些特征向量与 g 的汉明距离，得到汉明距离真正不超过 r 的那些特征向量。上述过程通常称为 r -近邻搜索 (r -neighbor search)， r 称为检索半径 (search radius)。

而那些被筛掉的，其汉明距离均大于 r 。

定理 3.4 如果 $\|h - g\|_{\mathbb{H}} \leq r$ ，则存在正整数 $k \in [1, m]$ 满足

$$\|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \leq \lfloor r/m \rfloor. \quad (3.3)$$

证明：依据鸽巢原理 (定理 3.3) 可得该结论；或直接利用反证法来证，如下。
假设对每一个 $k \in [1, m]$ 都有 $\|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \geq \lfloor r/m \rfloor + 1$ ，则可以得到

$$\|h - g\|_{\mathbb{H}} = \sum_{k=1}^m \|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \geq m \lfloor r/m \rfloor + m > m \lfloor r/m \rfloor + r \bmod m = r.$$

与已知条件 $\|h - g\|_{\mathbb{H}} \leq r$ 相矛盾。

□

3.3 应用：多索引哈希

给定一个待检索的特征向量 g ，要通过这 m 个哈希表找到与 g 的汉明距离不超过 r ($0 \leq r \leq d$) 的那些特征向量，就是依次根据 g 的第 k 个子向量 $g^{(k)}$ ，从第 k 个哈希表中筛出汉明距离可能不超过 r 的那些特征向量，然后再逐条计算这些特征向量与 g 的汉明距离，得到汉明距离真正不超过 r 的那些特征向量。上述过程通常称为 r -近邻搜索 (r -neighbor search)， r 称为检索半径 (search radius)。

而那些被筛掉的，其汉明距离均大于 r

定理 3.4 如果 $\|h - g\|_{\mathbb{H}} \leq r$ ，则存在正整数 $k \in [1, m]$ 满足

$$\|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \leq \lfloor r/m \rfloor. \quad (3.3)$$

依据上述结论，若数据库中的某个特征向量 h 与给定的特征向量 g 的汉明距离不超过 r ，则必存在 h 与 g 的对应的一对子向量，它们之间的汉明距离不超过 $\lfloor r/m \rfloor$ ，

进而在对应的哈希表中，通过计算哈希表的键值与对应的 g 的这个子向量的汉明距离就可以筛出这个特征向量（的标识符）

3.3 应用：多索引哈希

唯一标识符	特征向量
id_1	1000 1110 1001 0101
id_2	0010 0111 0100 0111
id_3	1000 1111 1100 0110
id_4	0000 1111 0111 1011
id_5	0101 0111 0011 1000
id_6	1010 1100 1110 0100
id_7	1011 1110 1011 0110
id_8	1110 0101 0110 0111
id_9	0111 1001 1110 1100
id_{10}	0110 1111 0001 0011
id_{11}	1101 0110 1111 1010
id_{12}	1010 1100 0110 1011
id_{13}	0011 1011 1110 0100
id_{14}	1110 1000 0000 0101
id_{15}	1111 1010 1000 1111
id_{16}	1110 1011 1100 1110
id_{17}	0000 0001 1100 1001

(a)

哈希表 1	
键	桶
0000	id_4, id_{17}
0001	
0010	id_2
<u>0011</u>	id_{13}
0100	
0101	id_5
0110	id_{10}
0111	id_9
1000	id_1, id_3
1001	
1010	id_6, id_{12}
1011	id_7
1100	
1101	id_{11}
1110	id_8, id_{14}, id_{16}
1111	id_{15}

(b)

哈希表 2	
键	桶
0000	
0001	id_{17}
0010	
0011	
0100	
0101	id_8
0110	id_{11}
0111	id_2, id_5
1000	id_{14}
<u>1001</u>	id_9
1010	id_{15}
1011	id_{13}, id_{16}
1100	id_6, id_{12}
1101	
1110	id_1, id_7
1111	id_3, id_4, id_{10}

(c)

哈希表 3	
键	桶
0000	id_{14}
0001	id_{10}
0010	
0011	id_5
0100	id_2
0101	
<u>0110</u>	id_8, id_{12}
0111	id_4
1000	id_{15}
1001	id_1
1010	
1011	id_7
1100	id_3, id_{16}, id_{17}
1101	
1110	id_6, id_9, id_{13}
1111	id_{11}

(d)

哈希表 4	
键	桶
0000	
0001	
0010	
0011	id_{10}
<u>0100</u>	id_6, id_{13}
0101	id_1, id_{14}
0110	id_3, id_7
0111	id_2, id_8
1000	id_5
1001	id_{17}
1010	id_{11}
1011	id_4, id_{12}
1100	id_9
1101	
1110	id_{16}
1111	id_{15}

(e)

希望从中找到与 0011 1001 0110 0100 的汉明距离不超过 2 的特征向量
如何快速找到？

$\{id_6, id_8, id_9, id_{12}, id_{13}\}$

3.3 应用：多索引哈希

算法 3.1 筛选算法一

输入： m 个哈希表，待检索特征向量 g ，检索半径 r

输出：与 g 的汉明距离不超过 r 的所有可能的特征向量的标识符集 ID

$ID \leftarrow \emptyset$;

for $k \leftarrow 1$ to m do

 在第 k 个哈希表中查找其键值与 $g^{(k)}$ 的汉明距离不超过 $\lfloor r/m \rfloor$ 的桶；

 将桶中的元素并入 ID ;

end for

return ID ;

3.3 应用：多索引哈希

算法 3.2 筛选算法二

输入： m 个哈希表，待检索特征向量 g ，检索半径 r ，界值 $a = r - m\lfloor r/m \rfloor$

输出：与 g 的汉明距离不超过 r 的所有可能的特征向量的标识符集 ID

$ID \leftarrow \emptyset$;

for $k \leftarrow 1$ to $a + 1$ do

 在第 k 个哈希表中查找其键值与 $g^{(k)}$ 的汉明距离不超过 $\lfloor r/m \rfloor$ 的桶；

 将桶中的元素并入 ID ;

end for

for $k \leftarrow a + 2$ to m do

 在第 k 个哈希表中查找其键值与 $g^{(k)}$ 的汉明距离不超过 $\lfloor r/m \rfloor - 1$ 的桶；

 将桶中的元素并入 ID ;

end for

return ID ;

3.3 应用：多索引哈希

算法3.2基于如下结论：

定理 3.5 令 $a = r - m[r/m]$ (即, a 为 r 除以 m 的余数), 令 A_1 和 A_2 是集合 $\{1, 2, \dots, m\}$ 的任一满足 $|A_1| = a + 1$ 和 $|A_2| = m - a - 1$ 的一个划分。如果 $\|h - g\|_{\mathbb{H}} \leq r$, 则要么存在正整数 $k \in A_1$ 满足

$$\|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \leq [r/m], \quad (3.4)$$

要么存在正整数 $k \in A_2$ 满足

$$\|h^{(k)} - g^{(k)}\|_{\mathbb{H}} \leq [r/m] - 1. \quad (3.5)$$

3.3 应用：多索引哈希

多哈希算法是一个典型的以空间代价换时间效率的算法。诺鲁齐、普贾尼和弗利特的实验展示，当子向量的长度接近 $\log_2 n$ 时，检索的平均效率最好，此时哈希表的个数 m 可依据 $\lfloor d/\log_2 n \rfloor \leq m \leq \lceil d/\log_2 n \rceil$ 进行设定。为分析简单，不妨设 m 整除 d 。该算法要多花费 m 个哈希表的空间，而每个哈希表都需要 $2^{d/m}$ 个桶存储 n 个特征向量的唯一标识符。譬如可以用一个数组作为一个哈希表，数组的长度为 $2^{d/m}$ ，其逻辑地址恰好对应从 0 至 $2^{d/m} - 1$ 的键值。理论上构建 n 个元素的唯一标识符需要 $n \lceil \log_2 n \rceil$ 个比特，从而这 m 个哈希表要存储这些特征向量的标识符还需要的存储空间为 $mn \lceil \log_2 n \rceil$ 个比特。

3.3 应用：多索引哈希

时间复杂度与被查询的桶的个数以及桶中标识符的个数有关。为简单起见，仍然假设 m 整除 d ，令子向量的长度为 $s = d/m$ 。给定检索半径 r ，在每个哈希表中要查询的桶的个数为：

$$\sum_{k=0}^{\lfloor r/m \rfloor} \binom{d/m}{k}。$$

依据二项式系数和的界值定理（定理 2.6）可以知道： m 个哈希表中要查询的桶的个数满足

$$m \sum_{k=0}^{\lfloor r/m \rfloor} \binom{d/m}{k} = m \sum_{k=0}^{\lfloor \frac{r}{d} \cdot \frac{d}{m} \rfloor} \binom{d/m}{k} \leq m 2^{\mathcal{H}(r/d) d/m}。$$

定理 2.6 (二项式系数界值定理) 已知 $0 < q \leq 1/2$ ，则

$$\sum_{k=0}^{\lfloor q \cdot n \rfloor} \binom{n}{k} \leq 2^{\mathcal{H}(q) \cdot n}, \quad (2.30)$$

其中 $\mathcal{H}(q) = -q \cdot \log_2 q - (1 - q) \cdot \log_2(1 - q)。$

3.3 应用：多索引哈希

时间复杂度与被查询的桶的个数以及桶中标识符的个数有关。为简单起见，仍然假设 m 整除 d ，令子向量的长度为 $s = d/m$ 。给定检索半径 r ，在每个哈希表中要查询的桶的个数为：

$$\sum_{k=0}^{\lfloor r/m \rfloor} \binom{d/m}{k}。$$

依据二项式系数和的界值定理（定理 2.6）可以知道： m 个哈希表中要查询的桶的个数满足

$$m \sum_{k=0}^{\lfloor r/m \rfloor} \binom{d/m}{k} = m \sum_{k=0}^{\lfloor \frac{r}{d} \cdot \frac{d}{m} \rfloor} \binom{d/m}{k} \leq m 2^{\mathcal{H}(r/d)d/m}。$$

假设 n 个标识符在一个哈希表的 $2^{d/m}$ 个桶中均匀分布，即每个桶中有 $n/(2^{d/m})$ 个标识符，从而定位这些桶并取出里面的标识符所需步数的上界为：

$$\left(1 + \frac{n}{2^{d/m}}\right) m 2^{\mathcal{H}(r/d)d/m} \stackrel{d/m = \log_2 n}{=} 2d \frac{n^{\mathcal{H}(r/d)}}{\log_2 n}。$$

当检索半径与特征向量长度之比非常小时，如 $r/d < 0.11$ 时 $\mathcal{H}(r/d) < 0.5$ ，则上述上界就变为

$$2d \frac{\sqrt{n}}{\log_2 n}。$$

作业

1. 已知 n 个整数 $a_1, a_2, \dots, a_n$, 证明: 存在整数 j 和 l ($1 \leq j \leq l \leq n$) 满足

$$n \mid \sum_{k=j}^l a_k,$$

其中: $\mid$ 是整除符号, 意味着左边的数整除右边的数。(提示: 构造连续项的和。)

2. 某棋手有 11 周时间准备比赛, 要求每天至少下 1 盘棋而任意连续的 7 天下棋盘数不能超过 12。证明: 在这准备期内某些连续的天中他恰好下了 21 盘棋。
3. 从 1 到 200 的所有正整数中任取 101 个, 则必能取到两个不同的数使得其中一个整除另一个。(提示: 任一正整数可写成 $2^k \cdot r$ 的形式, 其中 k 是非负整数, r 是奇数。)
6. 证明: 对任一正整数, 都存在它的一个倍数使得该倍数仅由数字 0 和 9 组成。如 1, 则有 $1 \times 9 = 9$; 如 2, 则有 $2 \times 45 = 90$; 又如 3, 则有 $3 \times 3 = 9$ 。

作业

10. 任给 $\{1, 2, \dots, n\}$ 的一个 n -元圆排列、以及任给一个整数 k ($1 \leq k \leq n$), 证明: 在这个圆排列中存在 k 个相邻的数, 它们的和不小于

$$\left\lceil \frac{k(n+1)}{2} \right\rceil.$$

13. 已知 $m_1, m_2, \dots, m_n$ 是两两互素的 n 个正整数, 而 $a_1, a_2, \dots, a_n, a$ 是整数。令

$$m = \prod_{k=1}^n m_k.$$

证明^⑨: 存在一个整数 $x \in [a, a+m)$ 满足

$$\forall k \in \{1, 2, \dots, n\} : x \equiv a_k \pmod{m_k}.$$

14. 编程实现多索引哈希算法, 并测试其性能。